

Caso de Estudio: Optimización de la Atención al Cliente en una Empresa de E-commerce - Implementación de un Sistema RAG para IA Generativa

Introducción

En el taller anterior, exploramos el poder de los modelos de IA generativa para mejorar la atención al cliente de EcoMarket para un set de dos tipos de prompts en particular. Ahora, se desea extender la capacidad del modelo de atención al cliente para que pueda responder ante cualquier tipo de solicitud, ya sea con la respuesta que parece correcta o haciéndole saber al usuario que no tiene las herramientas para atender su solicitud.

Los modelos de propósito general tienen una limitación clave: a menudo carecen de conocimiento específico y actualizado sobre la empresa, lo que puede llevar a respuestas incorrectas o "alucinaciones". En este taller, superaremos esta limitación al introducir un sistema **RAG (Generación Aumentada por Recuperación)**. Un sistema RAG permite que nuestro modelo de IA consulte una base de conocimiento interna antes de generar una respuesta, asegurando que esta sea precisa, relevante y basada en los datos de la empresa.

Fase 1: Selección de Componentes Clave del Sistema RAG

Antes de codificar, debemos tomar decisiones de arquitectura. En esta fase, los estudiantes seleccionarán los componentes principales del sistema RAG.

Preguntas guía:

- **Modelo de Embeddings:** ¿Qué modelo utilizarían para convertir los documentos de la empresa en vectores numéricos? Justifiquen su elección basándose en la precisión, el costo y la capacidad de manejar el idioma español. ¿Sería un modelo de código abierto como los de Hugging Face o uno propietario?
- **Base de Datos Vectorial:** ¿Dónde almacenarían estos vectores para que la búsqueda por similitud sea eficiente? Exploren opciones como Pinecone, ChromaDB o Weaviate. ¿Qué ventajas y desventajas tiene cada una para el caso de EcoMarket (escalabilidad, costo, facilidad de uso)?

Fase 2: Creación de la Base de Conocimiento de Documentos

El éxito de un sistema RAG depende de la calidad de la información que puede recuperar. En esta fase, los estudiantes prepararán la base de conocimiento para EcoMarket.

Pasos clave:

- **Identificación de Documentos:** Identifiquen al menos 3 tipos de documentos de la empresa de e-commerce que serían cruciales para el sistema de atención al cliente (ejemplos: política de devoluciones en PDF, una hoja de cálculo con el inventario de productos, un archivo JSON con preguntas frecuentes, etc.).
- **Segmentación (Chunking):** ¿Cómo dividirían estos documentos en "fragmentos" o *chunks* manejables? Discutan las diferentes estrategias de segmentación (por

tamaño fijo, por párrafos, de forma recursiva) y justifiquen por qué una estrategia es mejor que otra para este caso de uso.

- **Indexación:** Expliquen el proceso de tomar estos fragmentos, convertirlos en vectores con el modelo de *embedding* seleccionado y cargarlos en la base de datos vectorial.

Fase 3: Integración y Ejecución del Código

Esta es la fase práctica. Usaremos un *framework* popular para construir el flujo de RAG. El objetivo es que los estudiantes entiendan cómo se conectan las diferentes piezas, llevando a la práctica la propuesta realizada en las anteriores dos fases.

Generación del código:

1. **Preparación:** El script *rag_ejemplo.py* utiliza la librería **LangChain** para simplificar el proceso. Pueden también seguir el notebook que utilizamos en la sesión anterior que consideraba **LlamaIndex** para la construcción del sistema RAG.
2. **Código para la propuesta realizada:** Generar el código necesario para ajustar el modelo del Taller Práctico #1 e incorporar el sistema RAG definido en este taller.
3. **Detallar limitaciones y suposiciones:** En caso de tener limitaciones de recursos para ejecutar la propuesta definida en este taller, detallar claramente la razón de estas limitaciones y las suposiciones que se consideran para entender la arquitectura presentada.

Forma de entrega: Link del repositorio de GitHub que contiene la respuesta a las tres fases. Para las primeras dos, respuestas más textuales, los estudiantes deben usar algún formato de texto como Markdown para presentar la respuesta necesaria. Para la última fase, el repositorio mismo debe contener la estructura necesaria para ejecutar el código que utiliza un sistema RAG para obtener mejores respuestas.

Rúbrica de Evaluación del Taller (5 Puntos)

1. Selección y Justificación de Componentes (1.25 puntos)

- **1.25 puntos:** El estudiante selecciona un modelo de *embedding* y una base de datos vectorial **adecuados y justifica su elección de forma completa y bien argumentada**. La justificación considera factores clave como el rendimiento para el idioma español, el costo, la escalabilidad y las ventajas/desventajas de las opciones elegidas. Demuestra una comprensión profunda de cómo cada componente impacta en la eficacia del sistema RAG.
- **0.7 puntos:** El estudiante selecciona los componentes pero su justificación es **superficial o incompleta**. La elección no está claramente ligada a las necesidades específicas de EcoMarket o se basa en un solo factor (ej., solo la popularidad de la herramienta).
- **0 puntos:** La selección o la justificación de los componentes son incorrectas o irrelevantes.

2. Creación de la Base de Conocimiento (1.25 puntos)

- **2 puntos:** El estudiante identifica al menos **3 tipos de documentos relevantes** y propone una estrategia de **segmentación (chunking) lógica y bien justificada** para el caso de estudio. Demuestra un entendimiento de cómo la calidad de los documentos y la forma en que se dividen afectan directamente el rendimiento del sistema RAG.
- **0.7 puntos:** El estudiante identifica algunos documentos, pero no ofrece una estrategia de *chunking* clara o su justificación es débil. No logra explicar la importancia de este paso en el proceso de RAG.
- **0 puntos:** El estudiante no identifica documentos relevantes o no presenta un plan para la preparación de la base de conocimiento.

3. Comprensión del Código y la Integración (2.5 puntos)

- **2.5 puntos:** El estudiante demuestra una **clara comprensión de cada sección del código** proporcionado. Puede explicar cómo las piezas (modelo de *embedding*, base de datos vectorial y chaining) se conectan para formar el sistema RAG. Logra modificar el código o el *prompt* de forma exitosa para observar cambios en el comportamiento del modelo.
- **1.25 puntos:** El estudiante demuestra una **comprensión parcial de cada sección del código** proporcionado. Si bien se evidencian los cambios necesarios para agregar un sistema RAG, estos no son suficientes o no se ejecutan de la manera esperada dados los requerimientos y el diseño presentado.
- **0 puntos:** El estudiante no puede explicar la función de las diferentes partes del código o no logra ejecutar o modificar el script de forma exitosa.